


Fraud Data Analyst

Romain RAMAT
08/02/2026



- La fraude, un enjeu majeur et stratégique :
 - Perte financière
 - Risque de réputation et d'image

Le process



Données d'entrées du challenge :


4 Fichiers sont disponibles en entrées :

- **X_train** : variables explicatives pour l'entraînement
- **y_train** : variables cibles pour l'entraînement
- **X_test** : variables explicatives pour le test → **Non exploitable**
- **y_test** : variables cibles pour le test → **Non exploitable**

Le jeu « y_test » étant un exemple aléatoire composé de pourcentage et non de cas de fraude avéré, n'a pas été considéré dans le déroulé de l'exercice.

Analyse du jeu d'entraînement

Variable	Description	Exemple
ID (num)	ID unique	1
Item1 à 24	Catégorie du bien de l'item de 1 à 24	Computer
Cash_price1 à 24	Prix de l'item de 1 à 24	850
Make 1 à 24	Fabriquant de l'item	Apple
Goods_code1 à 24	Nombre de produits dans l'item 1 à 24	2
Nb of items	Nombre total d'items	7



Mise en place de features focus « Panier » :

Un bon modèle de détection de fraude :

- N'interdit pas
 - Ne juge pas
- Il observe des écarts



On ne dit pas : Téléphone Iphone 16 = Fraude

Mais :

Le contenu de ce panier ressemble **statistiquement** aux paniers frauduleux observés

Structure du panier :

- Nombre réel d'items
- Nombre d'items unique
- Taux de répétition

Le prix:

- Montant total du panier
- Prix max
- Prix moyen
- Dispersion des prix
- Ratio prix max/prix total

Les quantités:

- Quantité totale
- Quantité moyenne
- Quantité max

Diversité:

- Nbre catégorie unique
- Nbre marque unique
- Nbre de modèle unique

Transformation des items en feature exploitables par un algorithme de Machine Learning

Néanmoins il existe des catégories à risque :

CATEGORIE	TAUX_FRAUDE	NB_TRANSACTION
KITCHEN SCALES & MEASURES	100%	2
KITCHEN UTENSILS & GADGETS	35%	31
STORAGE & ORGANISATION	21%	39
LAUNDRY & CLOTHES CARE	15%	34
LUGGAGE	13%	15
PRESERVING & BAKING EQUIPMENT	11%	9
IMAGING EQUIPMENT	8%	85
MEN S CLOTHES	7%	59
BLANK MEDIA MEDIA STORAGE	6%	17
GAMING	6%	36
AUDIO ACCESSORIES	5%	1670
BARWARE	5%	41
NURSERY ACCESSORIES	5%	111
MEN S FOOTWEAR	4%	26
NURSERY LINEN	3%	29
HI-FI	3%	135
TABLEWARE	3%	681
TELEPHONES, FAX MACHINES & TWO-WAY RADIOS	3%	3138
JEWELLERY WATCHES	3%	36
BABY CHILD TRAVEL	3%	1161
TELEPHONES FAX MACHINES TWO-WAY RADIOS	3%	1513
DECORATIVE ACCESSORIES	3%	592
FRAGRANCE	3%	79
CARPETS, RUGS & FLOORING	2%	86
COMPUTERS	2%	50221
FULFILMENT CHARGE	2%	25023



Sont considérés à risque si :
Taux de fraude supérieur à
la moyenne globale (1,4%)
et + de 100 transactions




Nettoyage des données et mise en place des jeux de test

- $X = 15$ x "Feature engineering"
- $y = \text{"Fraud_flag"}$


train_test_split avec option « Stratify »

➔ Équilibrer les cas de fraude à 1 dans les jeux test et train



Modèle d'apprentissage supervisé : LightGBM


— LightGBM



Gestion du déséquilibre avec l'option
scale_pos_weight = (nb cas positif / nb
cas négatif) soit 69,36%

Paramètre	Catégorie	Description
objective = "binary"	Fonction de perte	Indique que la tâche est une classification binaire (fraude / non-fraude).
n_estimators = 2500	Structure du modèle	Nombre maximal d'arbres que LightGBM peut construire.
num_leaves = 127	Complexité des arbres	Nombre maximum de feuilles par arbre. Contrôle la capacité du modèle à capturer des patterns complexes.
learning_rate = 0.01	Vitesse d'apprentissage	Taille des pas de gradient. Plus c'est petit, plus l'apprentissage est stable.
min_data_in_leaf=150	Régularisation	Nombre minimum d'échantillons dans une feuille. Empêche les splits sur très peu de données.
feature_fraction=0,7	Sous-échantillonnage des features	À chaque arbre, LightGBM n'utilise que 70 % des colonnes.
bagging_fraction=0,7	Sous-échantillonnage des lignes	À chaque arbre, LightGBM n'utilise que 70 % des lignes.
bagging_freq=1	Fréquence du bagging	Active le bagging à chaque itération.
scale_pos_weight=70	Gestion du déséquilibre	Pondère la classe positive (fraude). Valeur $\approx$ ratio négatifs / positifs.
random_state=42	Reproductibilité	Fixe la graine aléatoire pour rendre les résultats identiques d'un run à l'autre.
Verbose=-1	Log	Désactive les logs LightGBM inutiles.

Calcul du PR-AUC et contrôle de stabilité



Contrôle de la stabilité du modèle sur 5 itérations

Itération Fold	Résultat PR-AUC
Fold 1	PR-AUC fold 1: 0.1690
Fold 2	PR-AUC fold 2: 0.1347
Fold 3	PR-AUC fold 3: 0.1550
Fold 4	PR-AUC fold 4: 0.1683
Fold 5	PR-AUC fold 5: 0.1349

Moyenne : 0.152
Écart-type : 0.0152

